

Chatbots und Retrieval-Augmented Generation

Deutsch

Teil 1: Deutsch

Lernumfang und Fokus

Diese Übersicht ist bewusst im Stil einer „Scope / Out-of-scope“-Liste aufgebaut (wie in deinem Moodle-Beispiel), aber thematisch auf **Chatbots** und **Retrieval-Augmented Generation (RAG)** zugeschnitten. Inhaltlich orientiert sie sich an etablierten Grundlagenwerken zu Dialogsystemen, zentralen RAG-/Retrieval-Papers sowie an aktuellen Industrie-Leitfäden (z. B. Cloud-RAG-Guides, Tool-Calling-Dokumentation, Security-Checklisten). ¹

Zielkompetenzen (was du am Ende sicher können solltest): Du kannst präzise erklären, **wie ein moderner LLM-Chatbot aufgebaut ist**, wann man **RAG** statt (oder zusätzlich zu) „Tool Use“ einsetzt, wie Retrieval (BM25 vs. Dense Retrieval vs. Hybrid) funktioniert, und wie man RAG-Systeme **evaluiert** und **absichert**. ²

In scope („prüfungsrelevante“ bzw. „lernrelevante“ Themen, wenn du das wie eine Klausur strukturieren willst):

- **Grundbegriffe & Modelle:** Was ist ein Chatbot/Dialogsystem, was ist ein LLM-Chatbot, was ist RAG (parametrisches vs. nicht-parametrisches Wissen), und welche Fehlerklassen sind typisch (z. B. Halluzinationen, Retrieval-Fehler, Prompt-Injection-Risiken). ³
- **LLM-Grundlagen, die Chatbots praktisch betreffen:** Instruction-Following/Alignment (z. B. RLHF-Idee), Kontextfenster-Limitierungen und warum lange Kontexte teuer/schwierig sind (quadratische Self-Attention als Kernproblem; viele Long-Context-Tricks sind „Mitigation“, nicht Magie). ⁴
- **Chatbot-Systemdesign:** Orchestrierung, Zustandsverwaltung, Guardrails, Tool-Calling/Function-Calling, „Memory“-Strategien (Conversation State vs. Langzeitwissen), Logging/Observability. ⁵
- **RAG-Pipeline End-to-End:** Datenaufbereitung (Parsing, Chunking), Embeddings, Indexierung, Retrieval, Re-Ranking, Prompt-Grounding (Kontext + Zitate/Provenienz), Caching. ⁶
- **Information Retrieval (IR) für RAG:** Lexikalisches Retrieval (TF-IDF/BM25-Familie), Dense Retrieval (Dual-Encoder, DPR-Idee), Hybrid Search & Score-Fusion (z. B. RRF), klassische Metriken (Recall, nDCG@k). ⁷
- **Evaluation von RAG-Systemen:** Trennung von Retrieval-Qualität und Generation-Qualität; „reference-free“ RAG-Evaluation (z. B. RAGAs-Ansatz) und Benchmarks für Retrieval-Modelle (z. B. BEIR-Gedanke: heterogene Datensätze, Zero-shot-Evaluation). ⁸
- **Risiken, Security & Governance:** Prompt Injection, Data Poisoning, DoS, Supply-Chain-Risiken (OWASP Top-10-LLM); AI-Risk-Management (z. B. NIST ⁹ AI RMF, ISO ¹⁰ 23894) und – für Europa – grobe Zeitleiste zum EU AI Act (wichtige Stichtage) plus Datenschutzbasis (GDPR). ¹¹

Out of scope (bewusst ausgeklammert, wenn dein Ziel „schnell solide Systeme bauen & beurteilen“ ist):

Training eines Foundation-Models „from scratch“, Beweise/Komplexitätsdetails jenseits der

Kernaussage „Self-Attention skaliert schlecht“, GPU-Kernel-Optimierungen im Detail (FlashAttention-Implementationsdetails), oder vendor-spezifische CLI-Optionen/Produkt-UIs. (Die Konzepte sind wichtiger als Tool-Menüs.) ¹²

Chatbot-Systeme: Architektur und Kernkonzepte

Ein moderner Chatbot ist (praktisch betrachtet) **kein einzelnes Modell**, sondern ein System aus mehreren Schichten: UI/Channel → Orchestrator → LLM → Tools (APIs) → Daten/Memory → Antwort + Telemetrie. Dieses Systemdenken ist zentral, weil viele Fehler nicht „Modellfehler“, sondern **Orchestrations-/Daten-/Sicherheitsfehler** sind. ¹³

Dialog-Grundlagen, die bei LLM-Chatbots weiterhin gelten: Zustandsverwaltung (Conversation State), Turn-Taking, Ziel-/Task-Orientierung vs. Smalltalk, sowie robuste Fehlerbehandlung (Fallbacks, Nachfragen, Klärungsfragen). Diese Aspekte sind klassische Dialogsystem-Themen und bleiben relevant, auch wenn das NLU/NLG heute oft „im Modell“ steckt. ¹⁴

Alignment/Instruction-Following als Chatbot-Enabler: Viele Chatbots basieren darauf, dass Modelle per „Instruction-Following“ besser steuerbar werden. Ein einflussreicher Ansatz dafür ist Fine-Tuning mit menschlichem Feedback (RLHF-Linie), wie im InstructGPT-Paper beschrieben (Demonstrationsdaten → Reward-Modell → RL-Fine-Tuning). ¹⁵

Tool-Calling und Agentenlogik: Wenn ein Chatbot rechnen, Datenbanken abfragen, Tickets erstellen oder interne Systeme nutzen soll, braucht er Tool-Use (Function Calling). Tool-Calling wird typischerweise als mehrstufiger Dialog zwischen App und Modell beschrieben (Tool-Definitionen → Tool-Call → Ausführung im Code → Tool-Result zurück ans Modell). Das ist der Kern moderner „Agenten“-Setups. ¹⁶

Relevanter Praxis-Punkt: Orchestrierung gehört oft **in Code** (Loops, Conditionals, Ratelimits, Policy-Checks), während das Modell eher für Sprache, Auswahl und Synthese genutzt wird. ¹⁷

Kontextfenster und Memory-Illusion: Ein LLM „merkt“ sich nichts persistenterweise; es verarbeitet nur den aktuell gegebenen Kontext. Mehr Kontext ist nicht kostenlos: Transformer-Self-Attention wird (in der Standardform) durch quadratische Skalierung mit der Sequenzlänge begrenzt, weshalb lange Kontexte teuer und technisch anspruchsvoll sind. ¹⁸

Daraus folgt einer der Hauptgründe, warum RAG in Chatbots so verbreitet ist: statt alles „in den Prompt zu stopfen“ holt man gezielt relevante Stücke nach. ¹⁹

RAG-Architekturen und Retrieval

Definition (präzise, paper-nah): Retrieval-Augmented Generation kombiniert ein generatives Modell (parametrisches Wissen) mit einer externen, durchsuchbaren Wissensbasis (nicht-parametrisches Wissen, häufig ein Vektorindex). Das ursprüngliche RAG-Paper beschreibt genau dieses Zusammenspiel und diskutiert auch Vorteile wie Aktualisierbarkeit/Provenienz gegenüber rein parametrischen Modellen. ²⁰

Praktische RAG-Pipeline (klassisch):

1) **Ingestion & Chunking:** Dokumente werden geparkt und in „Chunks“ zerlegt (oft mit Overlap). Chunk-Größe/Overlap sind Stellschrauben: zu klein → Kontext fragmentiert; zu groß → Retrieval unscharf und Prompt teuer. Framework-Dokus (z. B. LlamaIndex ²¹) und Cloud-RAG-Guides behandeln Chunking als Kernphase. ²²

2) **Embeddings:** Ein Embedding-Modell bildet Text auf Vektoren ab, sodass semantisch ähnliche Texte nahe beieinander liegen. Sentence-BERT ist ein klassischer, stark zitierter Ansatz, der BERT-basierte Sentence Embeddings über ein Siamese-Setup einführt. ²³

3) **Indexierung & ANN:** Für große Datenmengen nutzt man Approximate Nearest Neighbor (ANN). Ein Standard-Baustein ist **HNSW** (Hierarchical Navigable Small World Graphs): ein graphbasierter ANN-Index, der hohe Recall-/Latenz-Trade-offs ermöglicht. ²⁴
Libraries wie **Faiss** sind verbreitet, weil sie große Ähnlichkeitssuchen unterstützen, inkl. Evaluation/Tuning und (teilweise) GPU-Beschleunigung; es gibt dazu auch eine ausführliche Design-/Prinzipien-Darstellung in einer neueren Faiss-Publikation. ²⁵

4) **Retrieval (Sparse vs. Dense vs. Hybrid):**

- **Sparse/lexikalisch:** BM25-Familie (probabilistisches Relevanz-Framework) ist ein IR-Klassiker und bleibt stark für exakte Terme, Codes, Produktnamen, Abkürzungen. ²⁶
- **Dense Retrieval:** DPR (Dense Passage Retrieval) zeigt das Dual-Encoder-Prinzip für Open-Domain QA und vergleicht explizit gegen BM25-Baselines (Top-k-Retrieval-Accuracy). ²⁷
- **Hybrid Search:** Moderne Systeme kombinieren sparse + dense, weil die Stärken komplementär sind (Token-Match + Semantik). Das wird in Cloud-Dokus als „mix dense and sparse embeddings“ beschrieben. ²⁸

5) **Re-Ranking & Multi-Stage Retrieval:** Ein übliches Muster ist „Retrieve breit → re-rank teuer“. Re-Ranking kann über Cross-Encoder oder late-interaction-Modelle laufen; ColBERT ist ein prominentes late-interaction-Retrieval-Modell. Auch Vektor-DB-Dokus beschreibt Re-Ranking als eigene Phase nach der ersten Retrieval-Stufe. ²⁹

6) **Score-Fusion:** Wenn du mehrere Retriever kombinierst, ist Reciprocal Rank Fusion (RRF) eine robuste, simple Fusionsmethode und wurde in SIGIR-Kontext als starkes Baseline-/Ensemble-Verfahren diskutiert. ³⁰

7) **Prompt-Grounding:** Die finalen (ggf. re-rankten) Passagen werden in den Prompt injiziert („Grounding Context“). Gute Praxis ist: Kontext strukturieren, Quellen/IDs mitschicken, und dem Modell klar sagen, dass es nur aus dem Kontext behaupten soll (oder Unsicherheit markieren). Das Ziel ist: weniger Halluzinationen und bessere Nachvollziehbarkeit. ³¹

„**Agentic RAG**“ (Trend): Neuere Guides unterscheiden „klassisches RAG“ (fixer Retriever → Kontext → Antwort) und agentische Varianten, bei denen ein Agent iterativ nachschlägt, Query-Rewriting macht, mehrere Retriever abfragt oder Schritt-für-Schritt Datenquellen auswählt. Cloud-RAG-Dokus nennt „agentic retrieval“ explizit als Variante mit anderen Bausteinen/Pipelines. ³²

Fortgeschrittene Retrieval-Tricks (wahlweise „in scope“, wenn du tiefer gehen willst): HyDE ist ein Beispiel für „LLM-gestütztes Retrieval ohne Labels“: erst hypothetisches Dokument generieren, dann dieses als Dense-Query in den Korpus einbetten und echte Dokumente holen (wobei das hypothetische Dokument auch falsche Details enthalten kann). ³³
Framework-Dokus (z. B. LangChain ³⁴) behandelt zudem Retriever-Abstraktionen, Text-Splitter, Vector Stores und mehrstufige RAG-Chains als Standardbausteine. ³⁵

Evaluation, Betrieb und Risiken

Warum Evaluation bei RAG zweigeteilt ist: Ein RAG-System kann „falsch“ sein, weil Retrieval falsch ist (irrelevante Chunks), oder weil die Generation unfaithful ist (das Modell erfindet trotz guter Quellen),

oder weil die Frage schlecht formuliert/ambig ist. Diese Trennung ist der Grund, weshalb Retrieval-Metriken (Recall, nDCG@k etc.) und Generation-Metriken getrennt betrachtet werden. ³⁶

Retrieval-Evaluation: BEIR ist ein bekannter Benchmark-Ansatz, der heterogene Retrieval-Tasks bündelt und Zero-shot-Evaluation betont; er wird oft genutzt, um Robustheit und Out-of-Domain-Verhalten zu testen. ³⁷

Für BM25-basierte Verfahren ist ein solides IR-Fundament wichtig (probabilistisches Relevanz-Framework, BM25/BM25F). Das lässt sich sehr gut über Standard-IR-Material abdecken. ²⁶

RAG-Evaluation (end-to-end): RAGAs (Retrieval Augmented Generation Assessment) ist ein verbreiteter Ansatz für (weitgehend) referenzfreie Evaluation von RAG-Pipelines; die Idee ist, RAG-Qualität über Komponentenmetriken wie Kontext-Relevanz und Faithfulness zu operationalisieren, ohne immer goldene Antworten zu brauchen. ³⁸

Halluzinationen bleiben ein Thema (auch mit RAG): RAG reduziert das Risiko, aber eliminiert es nicht, weil Halluzinationen ein generatives Grundproblem sind (Survey-Literatur systematisiert Metriken und Mitigations). RAG kann zusätzlich scheitern, wenn der Kontext *nicht ausreichend* ist oder Retrieval die falschen Belege liefert. ³⁹

Betrieb (Ops): In realen Systemen brauchst du Telemetrie: Retrieval-Logs (Queries, Top-k, Scores), Antwort-Logs, Latenzen, Kosten, User-Feedback, driftende Dokumente/Embeddings. Viele „Best practices“ werden in Cloud-RAG-Dokumentation als Prozess beschrieben (Content-Preparation, Indexing-Pipeline, iterative Verbesserung). ⁴⁰

Security-Risiken (sehr „in scope“): Die OWASP ⁴¹ Top-10-LLM-Liste benennt u. a. Prompt Injection, Insecure Output Handling, Training Data Poisoning, Model DoS und Supply-Chain-Risiken als zentrale Klassen. Für RAG heißt das praktisch: Dokumente können „vergiftet“ werden (Prompt-Injection-Text im Dokument), Retrieval kann sensible Inhalte „aus Versehen“ hochziehen, und Tool-Outputs können als Angriffsvektor dienen. ⁴²

Wenn du Plattform-Tools nutzt (z. B. File-Search-Tools), ist außerdem wichtig zu verstehen, wie Retrieval/Ranking/Thresholding konfiguriert wird und was „best practices out of the box“ wirklich bedeutet. ⁴³

Governance & EU-Kontext: Für Risikomanagement sind Frameworks wie NIST AI RMF und ISO/IEC 23894 relevant (Trustworthiness/Risk-Controls über den AI-Lifecycle). ⁴⁴

In der European Union ⁴⁵ ist außerdem der AI Act zeitlich gestaffelt: „entered into force“ 1. August 2024, volle Anwendbarkeit 2. August 2026, mit früheren/anderen Stichtagen für bestimmte Pflichten (z. B. Verbote/AI-Literacy ab 2. Februar 2025; GPAI-Obligationen ab 2. August 2025). ⁴⁶

Datenschutzgrundlage bleibt die GDPR-Regelung (Regulation (EU) 2016/679). ⁴⁷

Traduction française

Partie 2 : traduction française (du contenu ci-dessus)

Cette synthèse est construite dans le style « scope / out of scope » (comme ton exemple Moodle), mais appliquée aux **chatbots** et au **Retrieval-Augmented Generation (RAG)**, en s'appuyant sur des références académiques (dialogue systems, RAG, retrieval dense/sparse) et des guides industriels récents (RAG cloud, tool-calling, sécurité). ¹

Objectif : être capable d'expliquer **l'architecture d'un chatbot moderne**, quand et comment utiliser **RAG**, comment fonctionnent BM25 vs dense retrieval vs recherche hybride, et comment **évaluer** et **sécuriser** un système RAG de bout en bout. ⁴⁸

In scope : fondations (définitions, limites et erreurs typiques), notions LLM utiles en chatbot (instruction-following/RLHF, limites de fenêtre de contexte), design système (orchestration, état de dialogue, tool use), pipeline RAG (chunking → embeddings → index → retrieval → reranking → grounding), bases IR (BM25, DPR/dense retrieval, hybride, RRF), métriques (recall/nDCG), évaluation end-to-end (RAGAs), et sécurité/gouvernance (OWASP Top-10 LLM, NIST AI RMF, ISO 23894, repères UE AI Act + GDPR). ⁴⁹

Out of scope : entraînement complet d'un foundation model, détails d'optimisation GPU/kernel, ou détails ultra-spécifiques d'un produit (menus/CLI) — on privilégie les concepts transférables. ⁵⁰

Sur l'architecture : un chatbot moderne est un **système** (UI → orchestrateur → LLM → outils/APIs → mémoire/données → réponse + observabilité). Beaucoup d'échecs viennent de l'orchestration, de la donnée ou de la sécurité, pas uniquement du modèle. ⁵¹

RAG : le papier fondateur définit RAG comme la combinaison de la génération (mémoire paramétrique) et d'une base externe consultable (mémoire non paramétrique, souvent un index dense), pour améliorer l'actualité, la traçabilité et la factualité sur des tâches « knowledge-intensive ». ²⁰

Le pipeline pratique : chunking (avec overlap) ⁵², embeddings (ex. Sentence-BERT) ²³, index ANN (ex. HNSW) ⁵³, retrieval sparse (BM25) ²⁶ / dense (DPR) ²⁷ / hybride ²⁸, reranking (ex. ColBERT) ²⁹, fusion (RRF) ³⁰, puis grounding dans le prompt. ¹⁹

Évaluation : BEIR structure l'évaluation hétérogène et zero-shot en IR ⁵⁴, et RAGAs propose une évaluation (souvent) sans références pour mesurer pertinence du contexte et faithfulness. ⁵⁵

Sécurité : OWASP Top-10 LLM (prompt injection, poisoning, DoS, supply chain...) est très pertinent pour des systèmes RAG et des chatbots connectés à des outils. ⁴²

Gouvernance : NIST AI RMF et ISO 23894 donnent des cadres généraux de gestion des risques IA. ⁵⁶

Übersetzung deines Prompts ins Deutsche

Teil 3: Übersetzung deines Prompts + Nicht-Deutsch → Deutsch

Dein Prompt in gutem, natürlichem Deutsch (korrigiert und verkürzt)

„Bitte mache eine **tiefgehende Recherche** zu **Chatbots** und **Retrieval-Augmented Generation (RAG)**. Erstelle – ähnlich wie in meinem Beispieltext – eine strukturierte Übersicht mit **Lernumfang (in scope)** und **ausgeschlossenem Stoff (out of scope)** sowie klaren Schwerpunkten. Die Liste soll praxisnah sein: Architektur, Retrieval-Methoden, Evaluation, Betrieb und Risiken.“

Wörter/Ausdrücke aus deinem Prompt, die nicht Deutsch sind → auf Deutsch

- „Do deep research“ → „mache eine **tiefgehende Recherche**“ / „recherchiere **gründlich**“
- „Recherche approfondie“ → „**tiefgehende Recherche**“ / „**gründliche Recherche**“
- „Chatbot“ → „Chatbot“ (üblich) oder „**Dialogsystem**“
- „RAG“ → „**Retrieval-Augmented Generation**“ (oder kurz „RAG“)
- „list“ → „**Liste**“

- „example“ / „Beispiel“ (du hattest FR-Struktur) → „**Beispiel**“
- „Skip to main content“ → „**Zum Hauptinhalt springen**“
- „Scope“ → „**Umfang**“ / „(Prüfungs-)Stoffumfang“
- „out of scope“ → „**außerhalb des Umfangs**“ / „**nicht prüfungsrelevant**“
- „Completion requirements“ → „**Voraussetzungen**“ / „**Anforderungen**“
- „multiple answer“ → „**Mehrfachauswahl**“
- „open questions“ → „**offene Fragen**“
- „coding / scripting by hand“ → „**Code/Skripte von Hand schreiben**“
- „weighting“ → „**Gewichtung**“
- „General remark“ → „**Allgemeiner Hinweis**“

1 2 3 5 10 13 14 48 49 51 Speech and Language Processing

https://web.stanford.edu/~jurafsky/slp3/?utm_source=chatgpt.com

4 15 41 Training language models to follow instructions with human feedback

https://arxiv.org/abs/2203.02155?utm_source=chatgpt.com

6 19 20 21 31 Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

https://arxiv.org/abs/2005.11401?utm_source=chatgpt.com

7 26 The Probabilistic Relevance Framework: BM25 and Beyond

https://www.staff.city.ac.uk/~sbrp622/papers/foundations_bm25_review.pdf?utm_source=chatgpt.com

8 38 55 Automated Evaluation of Retrieval Augmented Generation

https://arxiv.org/abs/2309.15217?utm_source=chatgpt.com

9 50 Fast and Memory-Efficient Exact Attention with IO-Awareness

https://arxiv.org/abs/2205.14135?utm_source=chatgpt.com

11 42 OWASP Top 10 for Large Language Model Applications

https://owasp.org/www-project-top-10-for-large-language-model-applications/?utm_source=chatgpt.com

12 [1706.03762] Attention Is All You Need

https://arxiv.org/abs/1706.03762?utm_source=chatgpt.com

16 Function calling | OpenAI API

https://developers.openai.com/api/docs/guides/function-calling/?utm_source=chatgpt.com

17 Introducing advanced tool use on the Claude Developer ...

https://www.anthropic.com/engineering/advanced-tool-use?utm_source=chatgpt.com

18 [2004.05150] Longformer: The Long-Document Transformer

https://arxiv.org/abs/2004.05150?utm_source=chatgpt.com

22 52 Basic Strategies | LlamaIndex OSS Documentation

https://developers.llamaindex.ai/python/framework/optimizing/basic_strategies/basic_strategies/?utm_source=chatgpt.com

23 Sentence Embeddings using Siamese BERT-Networks

https://arxiv.org/abs/1908.10084?utm_source=chatgpt.com

24 53 Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs

https://arxiv.org/abs/1603.09320?utm_source=chatgpt.com

25 facebookresearch/faiss: A library for efficient similarity ...

https://github.com/facebookresearch/faiss?utm_source=chatgpt.com

- 27 **Dense Passage Retrieval for Open-Domain Question Answering**
https://arxiv.org/abs/2004.04906?utm_source=chatgpt.com
- 28 **About hybrid search | Vertex AI**
https://docs.cloud.google.com/vertex-ai/docs/vector-search/about-hybrid-search?utm_source=chatgpt.com
- 29 **ColBERT: Efficient and Effective Passage Search via ...**
https://arxiv.org/abs/2004.12832?utm_source=chatgpt.com
- 30 45 **Reciprocal Rank Fusion outperforms Condorcet and ...**
https://cormack.uwaterloo.ca/cormacksigir09-rrf.pdf?utm_source=chatgpt.com
- 32 40 **Retrieval Augmented Generation (RAG) in Azure AI Search**
https://learn.microsoft.com/en-us/azure/search/retrieval-augmented-generation-overview?utm_source=chatgpt.com
- 33 **Precise Zero-Shot Dense Retrieval without Relevance Labels**
https://arxiv.org/abs/2212.10496?utm_source=chatgpt.com
- 34 47 **REGULATION (EU) 2016/ 679 OF THE EUROPEAN ...**
https://eur-lex.europa.eu/legal-content/EN/TXT/PDF/?uri=CELEX%3A32016R0679&utm_source=chatgpt.com
- 35 **Retrieval - Docs by LangChain**
https://docs.langchain.com/oss/python/langchain/retrieval?utm_source=chatgpt.com
- 36 **BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation ...**
https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/file/65b9eea6e1cc6bb9f0cd2a47751a186f-Paper-round2.pdf?utm_source=chatgpt.com
- 37 54 **BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation ...**
https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/65b9eea6e1cc6bb9f0cd2a47751a186f-Abstract-round2.html?utm_source=chatgpt.com
- 39 **Survey of Hallucination in Natural Language Generation**
https://arxiv.org/abs/2202.03629?utm_source=chatgpt.com
- 43 **Assistants File Search | OpenAI API**
https://developers.openai.com/api/docs/assistants/tools/file-search/?utm_source=chatgpt.com
- 44 56 **Artificial Intelligence Risk Management Framework (AI RMF 1.0)**
https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf?utm_source=chatgpt.com
- 46 **AI Act | Shaping Europe's digital future - European Union**
https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai?utm_source=chatgpt.com